

Análisis de Algoritmos Aplicado: Redes Neuronales Convolucionales (CNN)

Cesar Alejandro Prieto Franco, Corona Espinoza Daniel Joel

27 de Noviembre de 2025



Fundamento Algorítmico: Multiplicación de Matrices

Los "Ojos" de la Autonomía

Permiten diagnósticos más rápidos y precisos: analizan radiografías y resonancias para detectar tumores, fracturas o neumonía con una precisión que a menudo supera al ojo humano.

Seguridad y Comodidad Digital

Son la tecnología invisible que usamos todos los días para interactuar con nuestros dispositivos y mantener la seguridad.

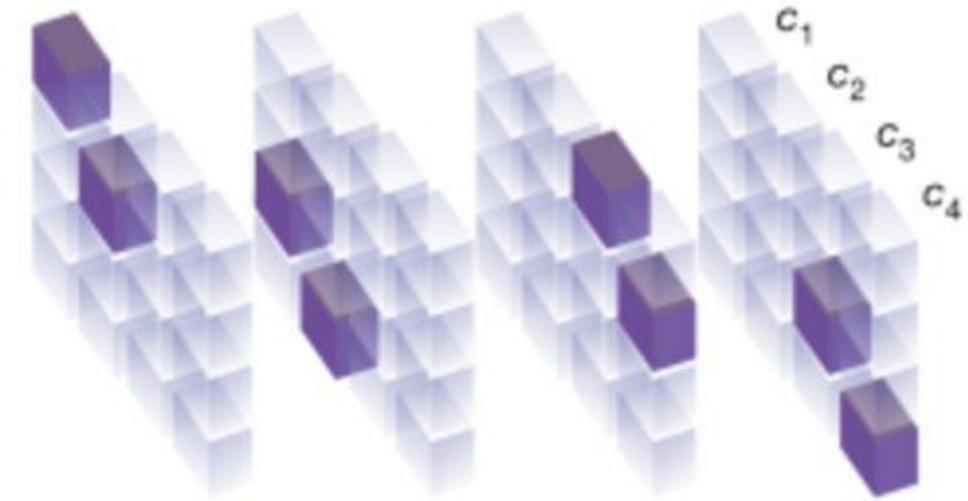
Los "Ojos" de la Autonomía

Sin las CNNs, los vehículos autónomos o los asistentes de conducción (como el de Tesla o los frenados de emergencia) no podrían existir.



ALGORITMO BASE

$$\begin{pmatrix} c_1 & c_2 \\ c_3 & c_4 \end{pmatrix} = \begin{pmatrix} a_1 & a_2 \\ a_3 & a_4 \end{pmatrix} \cdot \begin{pmatrix} b_1 & b_2 \\ b_3 & b_4 \end{pmatrix}$$



$$m_1 = (a_1 + a_4)(b_1 + b_4)$$

$$m_2 = (a_3 + a_4)b_1$$

$$m_3 = a_1(b_2 - b_4)$$

$$m_4 = a_4(b_3 - b_1)$$

$$m_5 = (a_1 + a_2)b_4$$

$$m_6 = (a_3 - a_1)(b_1 + b_2)$$

$$m_7 = (a_2 - a_4)(b_3 + b_4)$$

$$c_1 = m_1 + m_4 - m_5 + m_7$$

$$c_2 = m_3 + m_5$$

$$\dots = m_1 + m_2 + m_3 + m_4$$

MULTIPLICACIÓN DE MATRICES

La multiplicación de matrices es la herramienta matemática fundamental para modelar y transformar datos en la ingeniería y las ciencias de la computación. Su importancia general radica en que permite procesar, relacionar y transformar grandes volúmenes de información multidimensional de forma simultánea y eficiente. Es el motor indispensable detrás de la resolución de sistemas de ecuaciones complejos, la simulación de fenómenos físicos, la renderización de gráficos 3D y el procesamiento masivo de datos que requieren alto rendimiento computacional.

Introducción a la Red Neuronal Convolucional (CNN)



Fuerza Bruta

Usa el algoritmo estándar de tres bucles anidados para calcular el producto escalar. Es simple y exacto, pero su complejidad $\$O(n^3)\$$ lo hace muy ineficiente para procesar grandes volúmenes de datos.

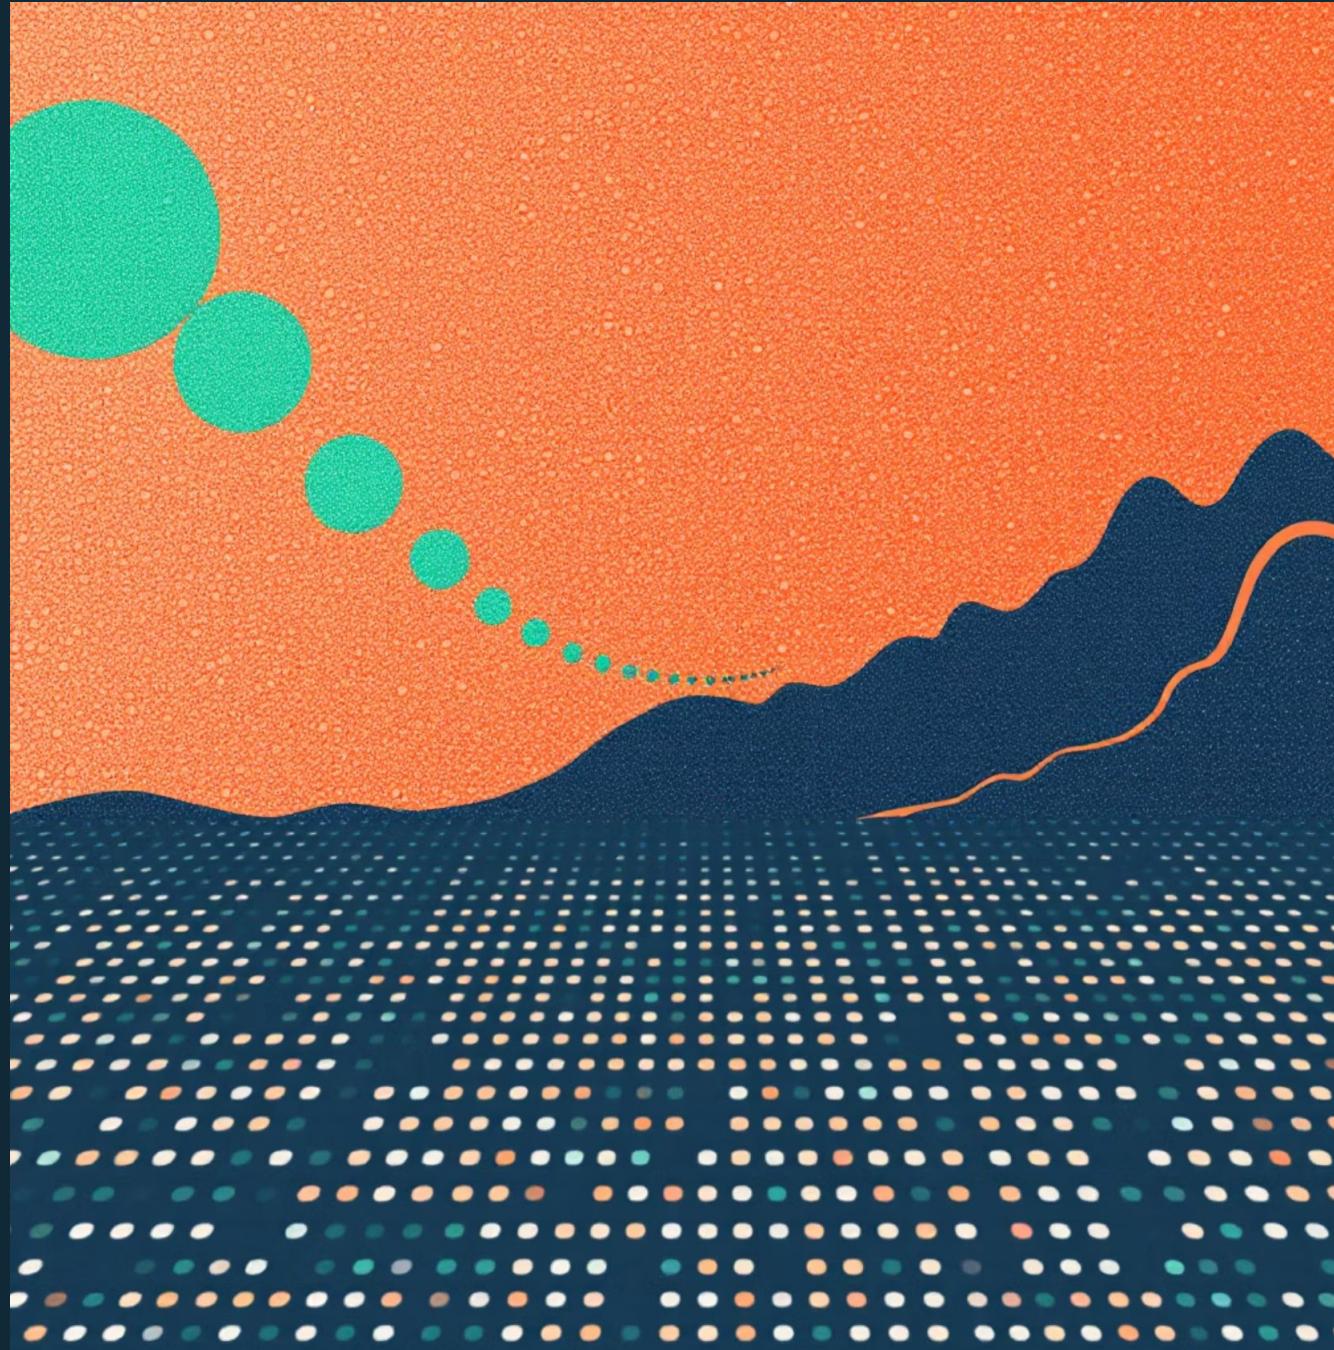
Divide y Vencerás

Descompone recursivamente las matrices en subbloques menores para procesarlos por separado. Esto reduce la cantidad de multiplicaciones necesarias y mejora significativamente el rendimiento en matrices grandes.

Técnica Voraz

Optimiza cadenas de matrices eligiendo el orden de asociación con menor costo inmediato. Su objetivo es minimizar el esfuerzo de cómputo total priorizando la opción más eficiente en cada paso local.

El Corazón del Algoritmo: La Capa de Convolución



Operación Matemática

Utiliza un **Kernel (Filtro)**, una matriz pequeña (ej. 3x3) que recorre la imagen de entrada.

Proceso Algorítmico

Se realiza el **producto punto** entre el filtro y la sección de la imagen para generar "Mapas de Características" (Feature Maps).

Conexión con el Curso

Aquí se aplica intensivamente la multiplicación de matrices optimizada, fundamental para la eficiencia de las CNN.



Arquitectura Profunda y Aprendizaje

1

Capas Intermedias (Pooling)

Reducen la dimensionalidad de la matriz para disminuir el costo computacional.

2

Forward Propagation

Paso de la información desde la entrada hasta la salida de la red.

3

Backpropagation

Cálculo del error y ajuste de los pesos mediante el gradiente descendente.

4

Funciones de Activación

ReLU/Softmax introducen no-linealidad para permitir decisiones complejas.

Análisis de Resultados mediante Grafos

Característica	Fuerza Bruta (Clásico)	Divide y Vencerás (Strassen)	Técnica Voraz (Greedy)
Enfoque Principal	Iterativo y secuencial.	Recursivo.	Heurístico (Optimización).
Lógica	Multiplica filas por columnas directamente usando 3 bucles anidados.	Divide las matrices en bloques menores ($n/2$) para reducir multiplicaciones.	Selecciona el orden de operaciones con el menor costo inmediato.
Complejidad (\$O\$)	$O(n^3)$	approx $O(n^{2.81})$ (ej. Strassen)	Varía (Optimiza la estructura, no el cálculo escalar).
Ventaja Clave	Fácil implementación y bajo uso de memoria RAM.	Más rápido asintóticamente para matrices muy grandes.	Toma decisiones ultrarrápidas para organizar recursos.
Desventaja	Ineficiente para grandes volúmenes de datos (muy lento).	<i>Overhead alto por recursión y gestión de memoria.</i>	No garantiza la solución globalmente óptima, solo local.
Uso Ideal	Matrices pequeñas o validación de resultados.	Computación de alto rendimiento (HPC) y Deep Learning.	Optimización de cadenas de multiplicación de matrices (Chain Order).

Resultados Experimentales

1

Precisión (Accuracy)

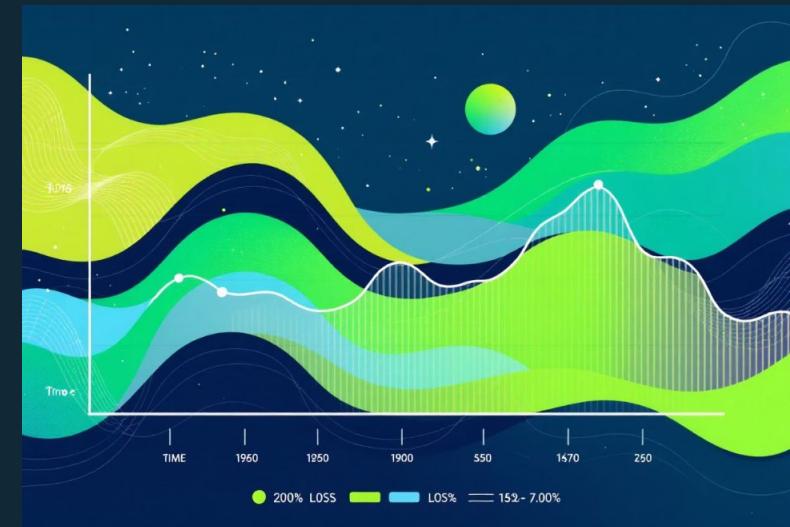
Gráfica que muestra la mejora de la precisión a lo largo de las épocas de entrenamiento.



2

Pérdida (Loss)

Gráfica que ilustra la disminución de la función de pérdida durante el entrenamiento.



3

Aceleración GPU

Comparativa del tiempo de entrenamiento en CPU vs. GPU (CuPy), mostrando una mejora significativa.





Conclusiones Clave



Integración Algorítmica

Las CNN son una compleja composición de algoritmos, incluyendo la multiplicación de matrices y optimización.



Escalabilidad Esencial

Sin técnicas como Strassen y el cómputo paralelo (GPU), el entrenamiento de redes profundas sería inviable.



Visualización Innovadora

Los algoritmos voraces (MST) ofrecen una nueva perspectiva para interpretar la "caja negra" de una red neuronal.

Gracias

